PEG-Parser, Pratt-Parser und Parser Combinators

BC George (HSBI)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

PEG (Parsing Expression Grammar) - Parser

Generative Systeme vs. Recognition basierte Systeme

- Generative Systeme:
  - formale Definition von Sprachen durch Regeln, die rekursiv angewendet Sätze/Strings der Sprache generieren
  - Sprachen aus der Chomsky Hierarchie definiert durch kontextfreie Grammatiken (CFGs) und reguläre Ausdrücke (REs)
- Recognition-basierte Systeme:
  - Sprachen definiert in Form von Regeln/Prädikaten, die entscheiden, ob ein gegebener String Teil der Sprache ist
  - Parsing Expression Grammar (PEG)

Beispiel

Sprache $L = \{\varepsilon,\ \mathrm{aa},\ \mathrm{aaaa},\ \ldots\}$:

- generativ: $L = \{s \in \mathrm{a}^* \mid s = (\mathrm{aa})^n,\ n \geq 0\}$
- recognition: $L = \{s \in \mathrm{a}^* \mid |s| \mod 2 = 0\}$

Motivation: Chomsky (CFGs + REs)

- ursprünglich für natürliche Sprachen
- adaptiert für maschinenorientierte Sprachen (Eleganz, Ausdrucksstärke)
- Nachteile:
  - maschinenorientierte Sprachen sollten präzise und eindeutig sein
  - CFGs erlauben mehrdeutige Syntax (gut für natürliche Sprachen)
  - Mehrdeutigkeiten schwer oder gar nicht zu verhindern
    - C++ Syntax
    - Lambda abstractions, `let` expressions und conditionals in Haskell
  - generelles Parsen nur in super-linearer Zeit

Motivation: PEG

- stilistisch ähnlich zu CFGs mit REs (EBNF)
- **Kernunterschied**: priorisierender Auswahloperator (`/` statt `|`)
  - alternative Muster werden der Reihe nach getestet
  - erste passende Alternative wird verwendet
  - Mehrdeutigkeiten werden dadurch unmöglich
  - nahe an der Funktionsweise von Parsern (Erkennen von Eingaben)
    - PEGs können als formale Beschreibung eines Top-Down-Parsers betrachtet werden
- Beispiel:
  - EBNF: $A \rightarrow a\ b \mid a$ und $A \rightarrow a \mid a\ b$ sind äquivalent
  - PEG: $A \leftarrow a\ b\ /\ a$ und $A \leftarrow a\ /\ a\ b$ sind verschieden

Definition PEG

Eine Parsing Expression Grammar (PEG) ist ein 4-Tuple $G = (V_N, V_T, R, e_S)$ mit

- V_N eine endliche Menge von Nicht-Terminalen
- V_T eine endliche Menge von Terminalen
- R eine endliche Menge von Regeln
- e_S eine *Parsing Expression*, die als *Start Expression* bezeichnet wird.

Weiterhin gilt:

- $V_N \cap V_T = \emptyset$.
- jede Regel $e \in R$ ist ein Paar (A, e), geschrieben als $A \leftarrow e$ mit $A \in V_N$, und e eine **Parsing Expression**
- für jedes Nicht-Terminal A existierte genau ein e mit $A \leftarrow e \in R$.

Definition Parsing Expression

Parsing Expressions werden rekursiv definiert: Seien e, e_1 und e_2 Parsing Expressions, dann gilt dies auch für

- den leeren String ε
- jedes Terminal $a \in V_T$
- jedes Nicht-Terminal $A \in V_N$
- die Sequenz $e_1 e_2$
- die priorisierende Option e_1 / e_2
- beliebige Wiederholungen e^*
- Nicht-Prädikate $!e$

Operatoren für Parsing Expression

Folgende Operatoren sind für die Konstruktion von **Parsing Expressions** erlaubt:

Operator	Priorität	Beschreibung
' '	5	String-Literal
" "	5	String-Literal
[ ]	5	Zeichenklasse
.	5	beliebiges Zeichen
(e)	5	Gruppierung
e?	4	Optional
e*	4	Kein-oder-mehr
e+	4	Ein-oder-mehr
&e	3	Und-Prädikat
!e	3	Nicht-Prädikat
e1 e2	2	Sequenz
e1 / e2	1	priorisierende Auswahl

PEG Eigenschaften

- andere Sprachklasse als CFGs
- parsierbar in linearer Zeit mit unbegrenztem Lookahead (Packrat Parsing)
  - Nachteil: gesamter zu parsender Text muss im Speicher gehalten werden
- neue Möglichkeiten für das Syntax-Design von Sprachen
- Syntaxbeschreibung: keine Unterscheidung zwischen Hierarchie und lexikalischen Elementen nötig
- Herausforderung bei PEGs:
  - sind Alternativen vertauschbar, ohne die Sprache zu ändern?
  - Analog zur Frage der Mehrdeutigkeit bei CFGs

Beispiel: Formeln

```
Expr   <- Term ([-+] Term)*
Term   <- Factor ([*/] Factor)*
Factor <- '(' Expr ')' / [0-9]+
```

Achtung: Die Grammatik ist rechtsassoziativ

Beispiel: Verschachtelte Kommentare

Verschachtelte Kommentare sind möglich, da die lexikalische Syntax von PEGs nicht auf REs beschränkt ist:

```
Comment       <- CommentStart CommentBody* CommentEnd
CommentStart  <- '/*'
CommentEnd    <- '*/'
CommentBody   <- Comment / (!CommentEnd AnySingleChar)
AnySingleChar <- .
```

oder in Kurzform

```
Comment <- '/*' (Comment / !'*/' .)* '*/'
```

Beispiel: Beliebige Escape-Sequenzen

Escape-Sequenzen haben meist nur eine stark eingeschränkte Syntax. Eine PEG kann beliebige Ausdrücke in eine Escape-Sequenz erlauben:

```
Expression  <- ...
Literal     <- ["] (![“] [Character EscSequence])* ["]
Character   <- !'\\' .
EscSequence <- '\\(' Expression ')'
```

Zum Beispiel könnte man dadurch in einer Escape-Sequenz auf Variablen zugreifen (`\(var)`) oder arithmetische Ausdrücke verarbeiten (`\(1+2)`).

Beispiel: Verschachtelte Template Typen in C++

Bekanntes Problem mit Template-Definitionen in C++: Leerzeichen zwischen Winkelklammern nötig um Interpretation als Pipe-Operator (`>>`) zu verhindern:

```
TypeA<TypeB<TypeC> > MyVar;
```

PEG erlaubt kontextsensitive Interpretation:

```
Expression      <- ...
TemplateType    <- PrimaryType (LEFTANGLE TemplateType RIGHTANGLE)?
ShiftExpression <- Expression (ShiftOperator Expression)*
ShiftOperator   <- LEFTSHIFT / RIGHTSHIFT
Spacing         <- any number of spaces, tabs, newlines or comments

LEFTANGLE       <- '<' Spacing
RIGHTANGLE      <- '>' Spacing
LEFTSHIFT       <- '<<' Spacing
RIGHTSHIFT      <- '>>' Spacing
```

Beispiel: Dangling-Else

In CFGs sind verschachtelte if-then(-else) Ausdrücke mehrdeutig (Shift-Reduce-Konflikt). Dies wird häufig durch informelle Meta-Regeln oder Erweiterung der Syntax aufgelöst. In PEGs sorgt der prioriserende Auswahloperator für das korrekte Verhalten.

```
Statement <- IF Cond Statement ELSE Statement
           / IF Cond Statement
           / ...
```

Beispiel: Nicht-CFG-Sprachen

Ein klassisches Beispiel einer nicht-CFG Sprache ist $a^n b^n c^n$. Diese Sprache lässt sich mit der folgenden PEG darstellen:

$$G = (\{A, B, S\}, \{a, b, c\}, R, S)$$

$$A \leftarrow a\ A\ b\ /\ \varepsilon$$

$$B \leftarrow b\ B\ c\ /\ \varepsilon$$

$$S \leftarrow \&(A\ !b)\ a^*\ B\ !.$$

Operator Precedence Parsing

Motivation

- Anforderungen an Recursive Descent
  - Modelliere Grammatik(-regeln) durch rekursive Funktionen
  - Top-Down-Ansatz
  - i.d.R. LL(1) Parser (handgeschrieben)
  - Linksrekursion (für handgeschriebene Parser von geringer Bedeutung; ersetzbar durch Schleife, EBNF)
  - Vorrangregeln (Precedence/Binding Power) und Assoziativität von Operatoren
  - Effizienz (Backtracking)

Eigenschaften von Operator Precedence Parsing

- Recognition-basiert (insofern als der Parser nicht aus einer Grammatik generiert, sondern von Hand geschrieben wird)
- verwendet Vorschautoken
- benutzt sowohl Rekursion als auch Schleifen
- interpretiert die Operator-Precedence-Grammatik
  - Untermenge der deterministischen kontextfreien Grammatiken
- simpel zu programmieren, kann die Operator-Tabelle während der Programmlaufzeit konsultieren
- verwendet eine Reihenfolge (precedence) für die Operatoren

Klassische Methode (RD)

- neues Nicht-Terminal für jeden Precedence-Level
- Nachteile:
  - Anzahl der Precedence Level bestimmt Größe und Geschwindigkeit des Parsers
  - Operatoren und Precedence Levels fest in Grammatik eingebaut

Dijkstras Shunting Yard Algorithmus (SY): Stack statt Rekursion

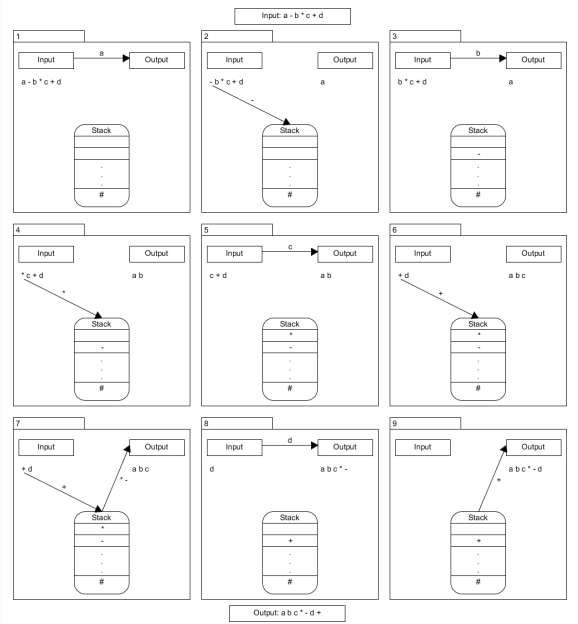

Dijkstras Shunting Yard Algorithmus

```
while there are tokens to be read:
        read a token
        if the token is a number:
        output.add(token)
        if the token is an operator:
        if operator is a bracket:
            if left bracket:
                stack.put(token)
            else:
                check if left bracket is in stack
                while stack.top != left bracket:
                    output.add(stack.pop())
                output.add(stack.pop())     // pop left bracket
        else:
            while token.precedence < stack.top.precedence:
                output.add(stack.pop())
            stack.put(token)
```

Precedence Climbing (PC)

- Climb **down** the precedence levels
- Behandelt einen Ausdruck wie verschachtelte Unterausdrücke
  - Jeder Unterausdruck enthält das gemeinsame precedence level

```
2 + 3 * 4 * 5 - 6

|---------------|   : prec 1
    |-------|       : prec 2
```

- Die Operatoren stehen mit Gewicht und Assoziativität (left, right) in einer Tabelle

Precedence Climbing - Beispielalgorithmus

```
fn expr(prec_bound) {
  result = atom() // number or an expression in braces

  loop {
    operator = nextToken()
    (prec, assoc) = lookup(operator)
    if (prec <= prec_bound) { break; }

    next_bound = if (assoc.left?()) { prec + 1 } else { prec }
    rhs = expr(next_bound)

    result = compute(operator, result, rhs)
  }

  return result
}
```

Top Down Operator Precedence (TDOP) Pratt Parsing

- Generalisierung von Precedence Climbing
- Verwendet eine Gewichtung (binding Power) statt einer Reihenfolge (precedence)
  - lbp = left Binding Power
  - rbp = right Binding Power

Tokenhandler

- Die Tokenhandler behandeln Notationen unterschiedlich
  - infix notation: a = b - c
    - led (left denotation)
  - prefix from: a = -b
    - nud (Null denotation)

```
op_token_sub = {
  lbp: 10,
  // '-' has two roles
  prefix: () => { -expression(100) }, // negation
  infix: (left) => { left - expression(10) }, // subtraction
}
op_token_mul = {
  lbp: 20,
  prefix: none, // '*' has only one role
  infix: (left) => { left * expression(20) }, // multiplication
}
```

Top Down Operator Precedence-Beispiel

```
fn expression(rbp = 0) {
  token = tokens.next()
  left = token.prefix()
  while rbp < tokens.current().lbp {
    token = tokens.next()
    left = token.infix(left)
  }

  return left
}
```

Right Associative TDOP

- Der Parser behandelt die folgende Potenzierungsoperatoren als Unterausdrücke des ersten Unterausdrucks
- Dies wird erreicht, indem wir den Ausdruck im Handler der Potenzierung mit einem rbp aufrufen, der niedriger ist als der lbp der Potenzierung

```
op_token_pow = {
  lbp: 30,
  infix: left => {
    left ** expression(30 - 1) // RECURSIVE CALL
  },
}
```

- Wenn die Funktion *expression* zum nächsten ^ in seiner Schleife gelangt, wird festgestellt, dass noch `rbp < tokens.current().lbp` ist und das Ergebnis nicht sofort zurückgegeben, sondern zunächst der Wert des Unterausdrucks gesammelt.

Vergleich

- Shunting Yard, TDOP und Precedence Climbing sind im Wesentlichen derselbe Algorithmus:
- Im Gegensatz zum klassichen RD ist das Hinzufügen/Ändern von Operatoren einfach
  - RD: Hinzufügen/Ändern von Funktionen im Parser
  - SY/TDOP/PC: Daten liegen in Tabellenform vor
- Mischformen möglich
- Shunting Yard verwendet einen Stack anstatt Rekursion
- Precedence Climbing wird am häufigsten eingesetzt

Vergleich TDOP vs. Precedence Climbing

- TDOP(Pratt Parsing) vs. Precedence Climbing
  - Eine While Schleife mit rekursiven Aufruf mit Abbruchbedingung (binding Power/precedence)
  - Rechts-Assoziativität
    - In precedence climbing: $\text{next_min_prec} = \text{prec} + 1$ für left Assoziativität
    - In Pratt Parsing: rechte binding power rbp auf lbp-1 gesetzt und der rekursive Aufruf mit ihr durchgeführt
  - Klammern
    - In precedence climbing in der rekursiven Parsing Funktion behandelt
    - In Pratt Parsing können sie als nud-Funktion für das Token (behandelt werden

Anwendung

- Haskell
  - benutzerdefinierte Infix-Operatoren mit individueller Assoziativität und Vorrang-Regeln
  - Ein Beispiel für das Konultieren der Operator während der Laufzeit
- Raku
  - im Verbund mit zwei weiteren Parsern (Speed-up beim Parsen von arithmetischen Ausdrücken)
- Taschenrechner
  - Umwandlung Infix-Notation (menschenlesbar) in umgekehrte polnische Notation (optimiert für Auswertung)

Parser-Kombinatoren

Prinzip

- benutzt Funktionen höherer Ordnung:
  - Funktionen als Parameter
  - Funktion als Rückgabewert
- verwendet mehrere Parser als Input und gibt den Output des kombinierten Parser zurück:
  - Parse Tree
  - Index der Stelle im String die zum Stoppen des Parsers geführt hat
- Rückgaben der verwendeten Parser:
  - Success: {result, restString}
  - Failure: Error Message und Position

Simple Parser

Simple Parser, die nachher als Inputparameter für einen kombinierten Parser verwendet werden:

```
fn integer(input) {
  match = /^\d+/.applyTo(input)
  if (match) {
    matchedText = match.first
    return Ok({data: matchedText, rest: input.skip(len(matchedText))})
  }
  return Err({dataDesc: "an integer", input: input})
}
```

```
fn plus(input) {
  if (input.first == '+') {
    return Ok({data: "+", rest: input.skip(1)})
  }
  return Err({dataDesc: "'+'", input: input})
}

fn eof(input) {
```

Kombinierter Parser

Der kombinierte Parser sieht wie folgt aus:

```
fn apply(func, parsers) {
  return (input) => {
    accData = []
    currentInput = input
    parsers.each((parser) => {
      result = parser(currentInput)
      case result {
        Err: return result
        Ok(data, rest):
          accData.append(data)
          currentInput = rest
      }
    })
    return Ok({data: func(accData), rest: currentInput})
  }
}
```

Kombinierte Parser definieren

Der kombinierte Parser kann nun so definiert werden:

```
fn plusExpr(input) {
  // `_` because data of plus/eof is not needed for calculation
  return apply((num1, _, num2, _) => { num1 + num2 }, [
      integer,
      plus,
      integer,
      eof
    ])
}
```

Diese Zusammensetzung der Parser überprüft eine Plus-Expression mit Integern. Wichtig hierbei ist die richtige Reihenfolge der Parser.

Verwendung des Parsers

Nun muss noch eine Parse-Funktion geschrieben werden, um die kombinierten Parser auszuführen.

```
fn parse(parser, input) {
  result = parser(input)
  case result {
    Err(dataDesc, input):
      raise "Parse error!
          expected: '${dataDesc}'
          got: '${input}'
        "
    Ok:
      return result
  }
}
```

Ausführung des kombinierten Parsers

Führt man nun den Parser aus, kann es wie folgt aussehen:

```
# parse(plusExpr, "12+34")
-> {data: 46, rest: ""}

# parse(plusExpr, "12+34rest")
-> Uncaught: Parse error!
        expected: 'end of input'
        got: 'rest'
```

Wrap-Up

Wrap-Up

Top Down Parsing von Ausdrücken:

- Parsing Expression Grammar
- Operator Precedence Parsing
- Top Down Operator Precedence Parsing
- Parser-Kombinatoren

LICENSE

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.